项目报告

本项目实现了三个版本的代码,第一个版本实现了 Self-Attention 机制,实现模型推理文本续写, AI 对话(用 story 中的模型)。

第二个版本适配 Nvidia 加速软件栈后端 Nvidia, 用 chat 中的模型 tinyllama 1.1b,效果明显提升。

第三个版本添加混合精度推理,提高了推理速度。

一、通过指标:

实现模型推理

文本续写 cargo run --release

Once upon a timeOnce upon a time, a lively cat named Tom lived in the house. He loved to play with the license with his friend, a little girl named Lily. One day, Tom asked Tom to complete the live, but the living room was too big. Tom wanted to help her. He wanted to find the license with the license too.

"listen, Tom! You can't do it. Tom said, "Lizzy, can I help me find my license back?" Lizzy smiled and said, "Yes, I will help you." They both looked for the license and added.

When they came back, they found a big, dirty spoon hanfe. The lict stopped shake. Tom played with the spots in the park, and the license was still dirty. Tom's friends were surprise and and handy. They shared the arrow home with the centain, and Tom hand eyew more find selections.

相应参数

```
Available tensors:

model.layers.0.mlp.gate_proj.weight

model.layers.0.self_attn.d_proj.weight

model.layers.1.self_attn.d_proj.weight

model.layers.1.self_attn.d_proj.weight

model.layers.0.mlp.up_proj.weight

model.layers.0.self_attn.po_proj.weight

model.layers.0.self_attn.po_proj.weight

model.layers.0.self_attn.proj.weight

model.layers.0.inptllayernorm.weight

model.layers.0.inptllayernorm.weight

model.layers.0.inptllayernorm.weight

model.layers.0.inptllayernorm.weight

model.layers.0.inptloom_proj.weight

model.layers.1.imlp.down_proj.weight

model.layers.1.imlp.down_proj.weight

model.layers.1.imlp.down_proj.weight

model.layers.1.imlp.down_proj.weight

model.layers.1.imlp.down_proj.weight

model.layers.1.imlp.down_proj.weight

model.layers.1.self_attn.y_proj.weight

model.layers.1.self_attn.y_proj.weight

model.layers.1.self_attn.y_proj.weight

model.layers.0.self_attn.y_proj.weight

model.layers.0.self_attn.y_proj.weight

model.layers.0.self_attn.y_proj.weight

model.layers.0.self_attn.y_proj.weight

model.layers.0.self_attn.y_proj.weight

model.layers.1.self_attn.y_proj.weight

model.layers.1.se
```

AI 对话(用 story 中的模型应用模板模拟对话模型,将对话视作前文来自 AI 和 user 的续写)。cargo run chat --release

```
### the blo ### th
```

二、评优资格:

- 1、适配 Nvidia 加速软件栈后端 Nvidia, python3 frontend/terminal_chat.py 1.1 代码中实现了对 NVIDIA GPU 加速的支持:
 - (1) 代码中定义了设备枚举类型,明确区分了 CPU 和 CUDA 设备:

```
enum class Device {
  CPU,
  CUDA
};
```

(2) 张量类实现了设备感知功能,可以在 CPU 和 CUDA 设备间移动:

```
// 推断自代码中的使用方式
Tensor<float> residual({seq_Len, d_}, Device::CUDA);
Tensor<float> hidden_states({seq_Len, d_}, Device::CUDA);
```

(3) 实现了针对 GPU 优化的注意力机制计算:

```
cuda_OP::compute_att_output(att_scores, total_V, n_q_h_, dqkv_, att_heads, n_kv_h_);
```

(4) KV 缓存专门针对 CUDA 设备进行了优化,在输出日志上的体现:

[KVCache::KVCache] 初始化 KVCache, n_layers=22, max_seq_len=2048, head_dim=256, device=CUDA

1.2 主要适配思路

- (1) 计算设备抽象:代码采用了设备抽象层,将计算操作与具体硬件实现分离,使同一套代码可以在 CPU 和 CUDA 设备上运行。这种抽象使得模型可以根据可用硬件自动选择最优执行路径。
- (2) 算子双重实现:为每个关键算子提供了 CPU 和 CUDA 两种实现版本: OP 命名空间下的函数用于 CPU 计算,cuda_OP 命名空间下的函数用于 GPU 加速计算
- (3) 内存管理优化:针对 CUDA 设备的特性,代码实现了高效的内存管理策略:预分配临时张量以减少动态内存分配,使用视图操作(如 view)避免不必要的内存拷贝,实现了 KV 缓存以重用计算结果。
- (4) 批处理和并行计算:利用 NVIDIA GPU 的并行计算能力:实现了批量矩阵乘法,使用 CUDA 流进行并行计算,针对注意力机制的计算进行了特殊优化。

1.3 实验

基本配置

```
Config Loaded: ("architectures: ("LlamaProCausalLM"), "attention bias': False, 'bos token_id': 1, 'eos token_id': 2, 'hidden_act': 'silu', 'hidden_size': 2048, 'initializer_range'
: 0.02, 'intermediate_size': 5632, 'max_position_embeddings': 2048, "model_type': 'llama', 'num_attention_heads': 32, 'num_hidden_layers': 22, 'num_key_value_heads': 4, 'pretrainin
g_tp': 1, 'rms_norm_eps': 1e-05, 'rope_scaling': lone, 'rope_theat': 10000.0, 'time_word_embeddings': False, 'torch_dtype': 'bfloat'6', 'transformers_version': '4.35.0', 'use_cache'
: True, 'vocab_size': 32000)
Model size: 1100048384 parameters, 4196.35 MB

Model Configuration:
Hidden Size: 2048
Num Key Value Heads: 4

Num Attention Heads: 32
Num Key Value Heads: 4

Head Dimension: 64
```

Attention tensors信息

```
Layer 0 Attention Tensors:
Q projection shape: torch.Size([2048, 2048])
K projection shape: torch.Size([256, 2048])
V projection shape: torch.Size([256, 2048])
O projection shape: torch.Size([2048, 2048])
Layer 1 Attention Tensors:
Q projection shape: torch.Size([2048, 2048])
K projection shape: torch.Size([256, 2048])
V projection shape: torch.Size([256, 2048])
O projection shape: torch.Size([2048, 2048])
Layer 2 Attention Tensors:
Q projection shape: torch.Size([2048, 2048])
K projection shape: torch.Size([256, 2048])
V projection shape: torch.Size([256, 2048])
0 projection shape: torch.Size([2048, 2048])
Layer 3 Attention Tensors:
Q projection shape: torch.Size([2048, 2048])
K projection shape: torch.Size([256, 2048])
V projection shape: torch.Size([256, 2048])
0 projection shape: torch.Size([2048, 2048])
Layer 4 Attention Tensors:
Q projection shape: torch.Size([2048, 2048])
K projection shape: torch.Size([256, 2048])
V projection shape: torch.Size([256, 2048])
0 projection shape: torch.Size([2048, 2048])
Layer 5 Attention Tensors:
Q projection shape: torch.Size([2048, 2048])
K projection shape: torch.Size([256, 2048])
V projection shape: torch.Size([256, 2048])
```

```
Model Info:
vocab_size: 32000
n_layers: 22
n_q_h: 32
n_kv_h: 4
hidden_size: 2048
head_dim: 64
intermediate_size: 5632
Model Info:
vocab_size: 32000
n_layers: 22
n_q_h: 32
n_kv_h: 4
hidden_size: 2048
head_dim: 64
intermediate_size: 5632
[KVCache::KVCache] 初始化 KVCache, n_layers=22, max_seq_len=2048, head_dim=256, device=CUDA
Model initialized successfully.
```

对话示例,可以发现模型可以很好的利用存储在 KVCache 中的前文的信息,最后一个问题的回答可以与上文的回答有很强的关联。

```
Externity CVC Active C
```

- 2、混合精度推理 python3 frontend/terminal_chat.py
- 2.1、代码中混合精度推理的体现
- (1) 代码中定义了精度类型枚举,支持多种计算精度:

```
enum class PrecisionType {
FP32, // 单精度浮点
FP16, // 半精度浮点
BF16 // Brain浮点格式
};
```

(2) 模型构造函数中的精度参数

LlamaModel 构造函数接收计算精度参数,并在初始化时保存:

```
LlamaModel::LlamaModel(
    const std::unordered_map<std::string, Tensor<float>>
    const std::unordered_map<std::string, int>& config,
    PrecisionType compute_precision)
    : params_(params), compute_precision_(compute_precis
// ...

// 如果使用低精度,初始化转换权重
if (compute_precision_ != PrecisionType::FP32) {
    convert_weights_to_precision(compute_precision_);
}
```

(3) 权重精度转换: 当使用非 FP32 精度时,模型会调用 convert weights to precision 函数将权重转换为指定精度:

```
if (compute_precision_ != PrecisionType::FP32) {
  convert_weights_to_precision(compute_precision_);
}
```

4. CUDA 前向传播中的精度分支 forward cuda 函数根据不同精度类型执行不同的计算路径:

2.2、混合精度推理的主要思路

(1) 精度类型抽象:代码设计了精度类型抽象,将计算精度与具体实现分离,使模型能够根据需要选择不同精度。这种抽象使得同一套代码可以支持多种精度计算,提高了代码的灵活性和可扩展性。

- (2) 权重转换机制:实现了权重精度转换机制,在模型初始化时根据指定精度转换权重。这种方式避免了在推理过程中频繁转换精度,提高了计算效率。
- (3) 精度感知的计算路径: 为不同精度类型设计了独立的计算路径, 确保每种精度都能获得最优的性能。特别是在 CUDA 设备上, 针对 FP16 和 BF16 精度提供了专门的实现。
- (4)输入输出精度处理:在混合精度计算中,输入数据需要转换为目标精度, 而输出结果则需要转换回 FP32 以保持与外部接口的一致性。这种设计使得混合 精度计算对外部调用透明,同时内部可以充分利用低精度计算的性能优势。
- (5)性能与精度平衡:混合精度推理的核心思想是在保持足够精度的前提下提高计算性能。代码中的实现允许用户根据具体需求选择合适的精度类型,在性能和精度之间取得平衡。

2.3 实验

基本配置与 Attention tensors 信息

模型与 KVCache 信息

```
Model Info:
vocab_size: 32000
n_layers: 22
n_q_h: 32
n_kv_h: 4
hidden_size: 2048
head_dim: 64
intermediate_size: 5632
Model Info:
vocab_size: 32000
n_layers: 22
n_q_h: 32
n_kv_h: 4
hidden_size: 2048
head_dim: 64
intermediate_size: 5632
[KVCache: KVCache] 初始化 KVCache, n_layers=22, max_seq_len=2048, head_dim=256, device=CPU
[LlamaModel::cuda] Moving model parameters to CUDA...
[LlamaModel::cuda] Moving w_down21 to CUDA...
```

对话示例,可以发现模型可以很好的利用存储在 KVCache 中的前文的信息,最后一个问题的 回答可以与上文的回答有很强的关联。另外混合精度推理的速度更快一些。

```
[LlamaModel::cuds] Moving w_upi3 to CUDA...
[LlamaModel::cuds] All parameters moved to CUDA successfully
[KVache::cuds] & KVache::pud] & KVac
```